

武汉大学

sfGFP 变体设计思路与说明

成 员： 贾媛媛，卢煜铎，曾知三，李瑞阳，杨明珏

二〇二六年 六 月

目录

一 骨架选择与设计策略.....	3
1.1 骨架选择理由.....	3
1.2 设计策略.....	3
二 突变模块库.....	4
2.1 突变模块证据表.....	4
2.2 协同突变对.....	5
三 候选序列生成方法.....	5
3.1 序列来源与生成策略.....	5
3.2 模块排列组合生成序列.....	6
3.3 ProteinMPNN 补充生成.....	6
3.4 二硫键序列.....	7
3.5 候选池合并.....	7
四 亮度预测器构建.....	7
4.1 特征提取与特征矩阵构建.....	8
4.2 传统监督学习模型探索与失败分析.....	8
4.3 ESM-1v 零样本似然值作为亮度代理指标.....	9
五 热稳定性代理分构建.....	10
5.1 代理分定义.....	10
5.2 计算流程.....	10
5.3 局限性说明.....	11
六 筛选流程.....	11
6.1 硬过滤.....	12
6.2 亮度代理分计算.....	12
6.3 热稳定性代理分计算.....	12
6.4 综合排序与排序.....	12
6.5 分类排序与六条分配.....	13
6.6 筛选结果统计.....	13
八 辅助判断规则.....	17
8.1 表面电荷判据.....	17
8.2 被动二硫键判据.....	17
8.3 游离 Cys 风险判据.....	17
九 局限性声明.....	18
9.1 骨架依赖引起的性能限制风险.....	18
9.2 亮度与热稳定性代理分与实验指标的语义鸿沟.....	18
9.3 分类排序策略的主观性.....	18
9.4 突变模块库的固有限制.....	19

摘要：本方案以超折叠绿色荧光蛋白（sfGFP，238 个氨基酸）为骨架，整合文献验证的高价值突变模块进行排列组合，并通过 ProteinMPNN 结构生成及二硫键引入策略，构建候选序列库。亮度评估基于 ESM-1v 零样本对数似然值，热稳定性代理分采用 ESM-1v 似然值相对于 sfGFP 野生型的变化值，经长度归一化及 0 - 1 缩放。筛选流程采用分类排序策略（mpnn 取前 3、module 取前 2、ssbond 取 1），最终选出六条提交序列。在保守 sfGFP 核心的前提下，通过有限且有依据的突变组合设计兼具极高初始亮度与极限热稳定性的新型绿色荧光蛋白。

一 骨架选择与设计策略

1.1 骨架选择理由

本方案选择 sfGFP（Superfolder GFP，238 个氨基酸）作为唯一设计骨架，主要基于 sfGFP 的优良特性及二十年的工程验证基础。sfGFP 通过引入“超折叠”突变（如 S30R、Y39N、N105T、I171V 等），相比野生型 avGFP 在折叠效率和抗聚集能力上显著提升，且能容忍多种插入或表面突变而不丧失荧光。同时，sfGFP 保留完整的发色团形成核心（65 - 67 位：SYG/TYG），其周围残基网络经充分表征，突变风险低。自 2006 年报道以来，sfGFP 被广泛用作定向进化与理性设计的模板，大量有益突变位点已被实验确认，为本项目的模块库提供可靠文献来源。

1.2 设计策略

为规避破坏折叠或荧光的风险及符合比赛要求，采取以下设计策略：

(1) 发色团核心保守：第 65 - 67 位（天然序列 SYG 或 TYG）在任何候选序列中不得突变。ProteinMPNN 生成时通过 `fixed_positions_jsonl` 参数强制锁定该区域。

(2) 疏水核心保守：基于 sfGFP 晶体结构（PDB 2B3P），使用 Bio.PDB 精确计算发色团（CRO 基团，残基 66）周围 5 Å 范围内的所有蛋白残基（共 27

个，已排除水分子 HOH）。在 ProteinMPNN 运行时通过 `fixed_positions_jsonl` 参数将这些残基全部锁定，保护发色团微环境不受破坏。

(3) 突变位点限定于经验证的区域：所有突变均来自文献验证的高价值模块（共 10 个位点：S30R、N132D、E138D、Y145F、S147P、H148S、P151T、L155T、I199T、V206K），位于 sfGFP 表面、环区或柔性区域，远离结构核心。

(4) 长度与合法性约束：候选序列长度严格控制在 220 - 250 之间，首字符必须为 M，仅含 20 种标准氨基酸的大写单字母代码。同时与 `Exclusion_List.csv` 进行完全一致性比对，排除完全匹配的已知序列。

根据以上对发色团核心和疏水核心采取的保守策略，并通过引入文献充分验证的、位于安全区域的突变组合去探索更优性能的新型 sfGFP，是基于明确的风险判断而非疏忽。

二 突变模块库

2.1 突变模块证据表

下表汇总本方案采用的十个突变模块的基本信息及文献来源。所有位点均经过在 sfGFP 238aa 序列上的有效性验证（即确保为非同义替换），且位于 sfGFP 表面、环区或柔性区域，远离发色团核心。

表 3.1 突变模块证据表

突变位点	替换氨基酸	功能分类	文献来源
S30R	R	折叠增强	Pedelacq et al., 2006 (Superfolder GFP)
N132D	D	表面电荷优化	QC2-6 (FPbase)
E138D	D	单体化	Hirano et al., 2023 (StayGold)
Y145F	F	疏水核心优化	Pedelacq et al., 2006; MD 模拟验证
S147P	P	热稳定性增强	FPbase 数据库
H148S	S	亮度增强	YuzuFP 2025 (分子动力学指导设计)

突变位点	替换氨基酸	功能分类	文献来源
P151T	T	结构刚性增强	QC2-6 (FPbase)
L155T	T	结构刚性增强	QC2-6 (FPbase)
I199T	T	量子产率提升	青色 TGP 2025
V206K	K	单体性增强	FPbase 数据库

模块入选标准：在至少一篇同行评审文献中被实验验证能提升 GFP 亮度、折叠稳定性、热稳定性或单体性；位于 sfGFP 表面、环区或柔性区域，远离发色团和疏水核心；在 sfGFP 238aa 序列上可产生非同义替换。

2.2 协同突变对

文献及模块组合分析表明，上述十个突变位点在蛋白质三维结构上分布于不同区域（S30R 位于 β 桶表面离子网络，H148S 位于发色团微环境内部，E138D、N132D、V206K 位于表面电荷区域，Y145F、S147P、P151T、L155T 位于 β 桶内壁或 β 链转折处），空间上无直接接触或冲突。因此，本方案在模块排列组合时不预设协同或互斥约束，所有位点独立参与排列组合，由后续 ESM-1v 打分和分类排序筛选出最优组合。

三 候选序列生成方法

3.1 序列来源与生成策略

候选序列库由三部分汇合而成：文献验证的突变模块排列组合（module）、ProteinMPNN 结构引导生成（mpnn）、二硫键定点引入（ssbond）。三类序列在设计逻辑上互补——module 序列有直接的实验证据支撑，mpnn 序列探索结构兼容的序列空间，ssbond 序列代表基于化学原理的稳定性策略。

3.2 模块排列组合生成序列

步骤如下：

(1) 输入：sfGFP 野生型序列字符串（238 aa），十个突变模块的位点及替换氨基酸字典。突变模块库共包含 10 个位点：S30R、N132D、E138D、Y145F、S147P、H148S、P151T、L155T、I199T、V206K。所有位点均已在 sfGFP 238aa 序列上验证为非同义替换。

(2) 生成逻辑：对 10 个突变位点进行排列组合，每条序列随机选取 4 - 8 个突变。突变数量控制在 4 - 8 个之间，基于 Nature 2016 适应度景观研究的数据——4 个以上有害突变约半数失活，但文献验证的有益突变可容忍更高组合数（如 Superfolder GFP 成功整合 6 个额外突变，mBaoJin 整合 8 个突变）。

(3) 发色团保护：发色团核心（65 - 67 位，SYG/TYG）在任何情况下不参与排列组合，代码中通过 `if any(p in (65,66,67) for p in combo): continue` 强制跳过。

(4) 生成后处理：检查基本合法性（长度、字符集、首字母），使用 Python set 去重。

(5) 输出：module 候选序列共 247 条，保存为 CSV 文件，包含 Seq_ID、Sequence、Source（标记为“module”）。

3.3 ProteinMPNN 补充生成

该步 ProteinMPNN 是一个可以根据三维蛋白结构反推氨基酸序列的生成式模型，能生成在结构上合理但序列上可能与天然 GFP 差异显著的候选序列。具体步骤如下：

(1) 固定残基计算：基于 sfGFP 晶体结构 PDB 2B3P，使用 Bio.PDB 精确计算发色团（CRO 基团，残基 66）周围 5 Å 范围内的所有蛋白残基（共 27 个，已排除水分子 HOH）。这些残基在 ProteinMPNN 运行时通过 `fixed_positions_jsonl` 参数强制锁定，确保发色团微环境不被破坏。

(2) 运行 ProteinMPNN: 以 2B3P 结构为输入, 固定上述 27 个残基, 设置温度参数 $T=0.3$, 随机种子 $seed=42$, 生成 200 条序列。

(3) 序列清理与发色团修复: ProteinMPNN 生成的序列中, 发色团 CRO 基团被映射为丙氨酸 (AAA)。通过搜索发色团下游保守区域 VQCF 或 VDCF, 将其前 3 个残基替换为 SYG, 恢复发色团功能。修复后保留 161 条 (仅保留可通过 VQCF/VDCF 锚点精确定位的序列)。

(4) 硬过滤: 所有序列执行通用硬过滤——长度 220 - 250、仅含标准氨基酸、首字母 M、排除列表比对。

(5) 输出: mpnn 候选序列共 161 条, Source 标记为"mpnn"。。

3.4 二硫键序列

基于 sfroGFP2 文献的 C147 - C204 二硫键设计, 在 sfGFP 野生型序列基础上, 将第 147 位丝氨酸 (S) 和第 204 位苏氨酸 (T) 分别替换为半胱氨酸 (C)。经 2B3P 结构验证, C147 - C204 的 $C\beta$ 距离为 4.58 Å, 处于二硫键形成的理想范围内 (3.5 - 6.5 Å)。文献报道该二硫键对可使折叠速度提高 2 倍, 解折叠速度减慢 2000 倍, 稳定性提高 16 kJ/mol。

该序列不经过模块组合的批量过滤, 直接并入最终候选池, Source 标记为 "ssbond"。共生成 1 条。

3.5 候选池合并

将三部分生成的序列合并为总池: module 247 条 + mpnn 161 条 + ssbond 1 条 = 409 条。合并后按 Sequence 列去重, 重新分配 Seq_ID。Source 列用于追溯每条序列的来源。

四 亮度预测器构建

4.1 特征提取与特征矩阵构建

对每条训练序列及候选序列提取相同维度的特征向量，总维度为 1299，组成如下：

表 4.1 输入特征类别

特征类别	维度	说明
ESM-1v 嵌入	1280	使用 <code>esm1v_t33_650M_UR90S</code> 模型，取最后一层所有位置的平均池化向量
理化特征	5	净电荷数 ($D+E+R+K$)、GRAVY 疏水性指数、芳香族比例 ($F+Y+W$)、甘氨酸+脯氨酸比例、序列长度
发色团局部微环境	4	基于 PDB 2B3P，距离发色团任何原子 5Å 内的残基中，分别统计 D、E、R、K 的出现次数
模块标签	10	是否含有十个已知突变模块 (0/1 二值)

（发色团局部微环境特征计算细节：基于 PDB 文件 2B3P.pdb，使用 Bio.PDB 计算发色团（CRO 基团，残基 66）5 Å 范围内的所有蛋白残基（共 27 个，已排除水分子 HOH）。对于每条候选序列，统计该残基集合中 D、E、R、K 各自出现的次数，形成 4 维特征向量。若某残基在序列中突变为其他氨基酸，则不计入。）

所有特征经标准化后拼接为 (N, 1299) 的特征矩阵。

4.2 传统监督学习模型探索与失败分析

在特征矩阵构建完成后，本方案首先尝试使用传统监督学习方法训练亮度预测模型。训练数据来源于比赛提供的 GFP_data.xlsx，包含数万条 avGFP 突变体的氨基酸序列及其实验相对亮度值。

分别尝试了 XGBoost 回归器和随机森林回归器，使用五折交叉验证在训练集上评估性能。目标变量为实验相对亮度（非负连续值）。主要评估指标为五折平均 R^2 。

训练结果：XGBoost 的五折平均 R^2 为-0.0020；随机森林的五折平均 R^2 为-0.0015。两个模型均未能从训练数据中学到有效规律，交叉验证表现等价于随机猜测。

失败原因分析：训练数据中的序列绝大多数为 avGFP 骨架上的单点或双点突变体，序列间差异极小（仅 1 - 2 个氨基酸替换）。而本方案候选池中大量序列来自 ProteinMPNN 从头设计（平均每位点改动超过 40 个残基）以及 sfGFP 骨架上的多点组合突变（4 - 8 个突变）。训练集与预测集的特征分布存在系统性鸿沟：前者集中在一个狭窄的序列空间局部区域，后者分布在整个序列空间的广泛区域。XGBoost 和随机森林作为基于特征插值的模型，在面对训练集覆盖范围之外的序列时无法进行有效外推。

结论：基于 avGFP 历史突变数据训练的传统监督学习模型，不适用于本方案的候选序列空间。因此，本方案在后续筛选流程中未采用上述模型，转而使用 ESM-1v 的零样本对数似然值作为亮度排序的代理指标。

4.3 ESM-1v 零样本似然值作为亮度代理指标

选择依据：ESM-1v 是一个在数千万条天然蛋白序列上训练的掩码语言模型，其对数似然值 LL_{seq} 反映了序列整体符合天然蛋白质统计规律的程度。多项研究表明，该指标与蛋白质的折叠能力、突变耐受性和功能表达水平呈正相关。不同于传统监督学习模型，ESM-1v 的评估能力来源于其在大规模天然序列上的预训练，不依赖特定物种的实验数据，因此对各类序列具有更广泛的适用性。

与训练数据的相关性验证：为验证 ESM-1v 似然值与实验亮度的关联性，本方案在 GFP_data.xlsx 的训练数据上进行了探索性分析。从约 14 万条训练数据中随机采样 2000 条，计算每条序列的 ESM-1v 平均对数似然值，并与其实验亮度进行 Spearman 秩相关性检验。结果显示，两者的 Spearman 秩相关系数为 0.31

($p < 0.001$)，呈现中等程度的正相关。该相关性虽不足以进行精确的定量预测，但可以支持对候选序列进行粗粒度的优劣排序——这正是本方案筛选流程所需要的。

计算流程：

(1) 对每条候选序列，使用 ESM-1v 模型计算序列的平均对数似然 LL_{seq} (与第五章热稳定性代理分计算中的原始似然值相同)。

(2) 对所有候选序列的 LL_{seq} 进行 0 - 1 归一化，得到 $brightness_proxy = (LL_{seq} - min_LL) / (max_LL - min_LL)$ ，使得得分越高表示序列越符合天然蛋白质的统计分布。

使用方式与说明：该代理指标为排序指标，不直接预测实验亮度值。其数值不代表相对野生型 sfGFP 的亮度倍数，仅用于候选序列之间的相对比较。归一化后的得分范围为[0, 1]，得分越高表示序列在进化统计意义上越“天然”。该代理指标的局限性将在第九章局限性声明中与热稳定性代理分的局限性合并说明。。

五 热稳定性代理分构建

5.1 代理分定义

本方案不直接预测 72°C 加热后荧光保留率，而是引入一个可大规模计算且与折叠稳定性正相关的代理指标——ESM-1v 零样本对数似然值。

ESM-1v (650M 参数版本) 是一个在数千万条天然蛋白序列上训练的掩码语言模型。对于给定序列，模型可计算每个位置氨基酸的条件对数概率，整条序列的均值得分反映其符合天然蛋白质序列分布的程度。

5.2 计算流程

对每条候选序列及 sfGFP 野生型序列，其热稳定性代理分计算流程如下：

(1)加载 ESM-1v 模型（esm1v_t33_650M_UR90S），设置

repr_layers=[33],return_contacts=False

(2)对序列进行分词，输入模型，获取输出对数似然（logits）。

(3)对每个位置，取模型预测的真实氨基酸的对数概率；对所有位置求平均，得到序列的平均对数似然 LL_seq。

(4)计算相对变化：

$$\Delta LL = LL_candidate - LL_sfGFP \quad \text{式(1)}$$

(5)除以候选序列自身的长度 L_candidate，得到每残基的平均对数似然变化：

$$\Delta LL_per_res = \Delta LL / L_candidate \quad \text{式(2)}$$

该处理使得不同长度的序列（220 - 250）之间的 ΔLL_per_res 具有可比性，兼容 ProteinMPNN 生成的长度变异序列。

(6)对所有候选序列的 ΔLL_per_res 进行 0-1 归一化：

$$stability_score = (\Delta LL_per_res - \min_ALL) / (\max_ALL - \min_ALL) \quad \text{式(3)}$$

使得得分越高表示序列在进化分布上更接近天然蛋白，即折叠稳定性倾向越强。

5.3 局限性说明

该代理分与“72°C 加热后荧光保留率”在物理含义上并不同，代理分更偏向是一种排序指标，它仅反映序列的天然似然度。同时，该数值与实际物理真值间存在着尚未量化的偏差。因此，本方案将其作为排序指标而非绝对预测值使用，并在局限性声明部分中明确此偏差。所有候选在相同模型下计算，相对排序具有一定参考价值。

六 筛选流程

6.1 硬过滤

所有候选序列首先满足以下硬性条件，不符合任一条者直接淘汰：

(1)长度约束：序列长度必须在 220 至 250 个氨基酸之间（含两端）。

(2)起始氨基酸：序列第一个字符必须为甲硫氨酸（M）。

(3)字符合法性：序列仅允许包含 20 种标准氨基酸的大写单字母代码（A、C、D、E、F、G、H、I、K、L、M、N、P、Q、R、S、T、V、W、Y），不得出现任何其他字符。

(4)排除列表比对：逐条与比赛提供的 `Exclusion_List.csv` 中的禁止序列进行字符串完全比对，删除完全匹配的序列。

6.2 亮度代理分计算

对所有通过硬过滤的 409 条候选序列，按照第四章所述方法计算 ESM-1v 零样本对数似然值 `LL_seq`，并经 0 - 1 归一化得到亮度代理分 `brightness_norm`。该指标与实验亮度的 Spearman 秩相关系数为 0.31（中等正相关），可用于候选序列的相对排序。

6.3 热稳定性代理分计算

对上一步所有序列，按照第五章所述方法计算 ESM-1v 似然值差值（ ΔLL_{per_res} ），经长度归一化与 0 - 1 缩放得到稳定性代理分 `stability_norm`。同时计算野生型 sfGFP 的对应分数作为参照。

6.4 综合排序与排序

将每条序列的综合分定义为： $score_composite = brightness_norm \times stability_norm$ 。该乘积形式直接对应比赛双能乘积制评分公式（亮度 × 热稳定性）。

6.5 分类排序与六条分配

由于 ESM-1v 似然值天然偏向 ProteinMPNN 从头设计序列 (mpnn), 而 module 序列 (文献实证保险) 和 ssbond 序列 (二硫键策略) 在似然值排序中处于劣势, 若全池混排将导致文献策略被完全挤出六强。为对冲 ESM-1v 代理指标的不确定性, 本方案采用分类排序策略——在各自来源类别内部按综合分降序排列, 按固定名额分配:

mpnn 序列取前 3 条 (计算模型推荐, 冲刺综合高分)

module 序列取前 2 条 (文献实证保险, 保证基础分)

ssbond 序列取 1 条 (二硫键策略, 冲击最佳热稳定奖)

此策略既尊重 ESM-1v 在 mpnn 序列内部的排序能力, 又保留文献验证和二硫键策略的独立参赛机会, 形成方法论上的多元保险。

6.6 筛选结果统计

基于 all_candidates_scored_final.csv 中记录的 409 条候选序列的完整评分结果, 各筛选步骤的实际执行情况如下:

(1) 硬过滤: 409 条全部通过, 无序列被淘汰。

(2) 亮度代理分计算: 409 条序列的 ESM-1v 原始似然值范围为 $[-0.49, -0.41]$, 归一化后为 $[0, 1]$ 。

(3) 热稳定性代理分计算: 409 条序列的长度归一化差值范围为 $[-0.0001, 0.0002]$, 归一化后为 $[0, 1]$ 。

(4) 综合分计算与分类排序: 综合分=亮度代理分 $\times$ 热稳定性代理分。mpnn 取前 3 (综合分: 1.0000、0.9193、0.8837), module 取前 2 (综合分: 0.1373、0.1346), ssbond 取 1 (综合分: 0.0670)。

(5) 最终审查：六条序列全部通过格式审查、排除列表比对、发色团完整性检查、二硫键位点确认及 G166D 修复验证。。

七 最终序列设计定位

本章汇总经完整筛选流程（硬过滤 → 亮度代理分计算 → 热稳定性代理分计算 → 综合分计算 → 分类排序）后获得的六条最终序列。每条序列均有明确的设计定位，并附量化得分。

7.1 最终六条序列得分总览

表 7.1 最终选取序列信息

Seq_ID	来源	设计定位	亮度代理分	稳定性代理分	综合分
1	mpnn	综合高分（计算模型推荐）	1.0000	1.0000	1.0000
2	mpnn	综合高分（计算模型推荐）	0.9588	0.9588	0.9193
3	mpnn	综合高分（计算模型推荐）	0.9401	0.9401	0.8837
4	module	文献实证保险	0.3716	0.3694	0.1373

Seq_ID	来源	设计定位	亮度代理分	稳定性代理分	综合分
5	module	文献实证保险	0.3680	0.3659	0.1346
6	ssbond	二硫键策略（冲刺热稳定奖）	0.2584	0.2591	0.0670

7.2 各序列设计定位与选择理由

（1）（1）Seq_1（综合高分，mpnn）：来源于 ProteinMPNN 结构生成，综合分排名第一。

选择理由：该序列综合分（1.0000）为全池最高，亮度代理分和稳定性代理分均为 1.0000（在 409 条序列中均排第一），表明该序列在 ESM-1v 统计模型下同时具备最优的折叠倾向和天然序列特征。该序列携带完整的发色团 SYG（经 VQCF 锚点修复），C 端为 DELYK，长度为 232 aa，所有格式审查通过。选择该序列作为综合排名的核心代表。

（2）Seq_2（综合高分，mpnn）：来源于 ProteinMPNN 结构生成，综合分排名第二。

选择理由：该序列综合分为 0.9193，亮度代理分和稳定性代理分均为 0.9588，在全池中均排第二。与 Seq_1 类似，该序列同样经过发色团修复为 SYG，C 端为 DELYK。作为 mpnn 序列中次优代表，该序列在序列空间中与 Seq_1 略有差异（不同 VQCF/VDCF 锚点定位和修复批次），选入可提供计算模型推荐的另一独立样本。

(3) Seq_3 (综合高分, mpnn): 来源于 ProteinMPNN 结构生成, 综合分排名第三。

选择理由: 该序列综合分为 0.8837, 亮度代理分和稳定性代理分均为 0.9401, 在全池中均排第三。该序列的发色团修复和 C 端优化与前两条一致。选入该序列可进一步增加 mpnn 序列的代表性, 三条 mpnn 序列共同构成计算模型推荐的主力阵容。

(4) Seq_4 (文献实证保险, module): 来源于文献验证的突变模块排列组合, 综合分排名第四 (module 中排名第一)。

选择理由: 该序列的亮度代理分为 0.3716, 稳定性代理分为 0.3694, 综合分为 0.1373。虽然 ESM-1v 似然值显著低于 mpnn 序列, 但该序列的每一处突变 (来自 S30R、N132D、E138D、Y145F、S147P、H148S、P151T、L155T、I199T、V206K 的组合) 均有直接的文献实验证据支撑。选入该序列可对冲 ESM-1v 代理指标的系统性偏差风险——若实验结果表明 ESM-1v 似然值与真实荧光/热稳定性的相关性弱于预期, 文献验证的突变模块仍有独立的成功概率。该序列在最终审查中被确认 G166D 已修复为野生型 G。

(5) Seq_5 (文献实证保险, module): 来源于文献验证的突变模块排列组合, 综合分排名第五 (module 中排名第二)。

选择理由: 该序列综合分为 0.1346, 与 Seq_4 分数接近, 突变组合略有不同 (4-8 个突变的随机组合中的另一独立样本)。选入该序列可在文献实证路线上提供额外多样性, 进一步降低单一突变组合失效的风险。

(6) Seq_6 (二硫键策略, ssbond): 基于 sfGFP 野生型骨架引入 C147 - C204 二硫键对, 综合分排名第六。

选择理由: 该序列综合分为 0.0670, 显著低于 mpnn 和 module 序列。但该序列的设计逻辑独立于 ESM-1v 统计模型——二硫键 C147 - C204 经 2B3P 结构验证距离理想 (4.58 Å), 且有 sfroGFP2 文献的直接实验支撑 (折叠速度提高 2 倍, 稳定性提高 16 kJ/mol)。选入该序列旨在冲击最佳热稳定奖。关于 CFPS 体系中二硫键形成的效率不确定性, 已在设计文档相关章节中说明。

八 辅助判断规则

辅助判断规则不作为强制过滤条件，仅在精选池内两条或多条序列综合分极其接近且需要打破平局时启用。

8.1 表面电荷判据

对综合分极其接近的两条或多条序列，可统计序列中天冬氨酸（D）、谷氨酸（E）、精氨酸（R）、赖氨酸（K）的总数，记为 `charge_count`。计算该值与野生型 sfGFP 对应统计值的差值绝对值 $\Delta\text{charge} = |\text{charge_count} - \text{charge_sfGFP}|$ 。 Δcharge 越大，说明序列整体表面净电荷变化越大——通常意味着更好的溶解度和热耐受性，因而优先保留 Δcharge 更大的序列。

8.2 被动二硫键判据

基于 sfGFP 晶体结构（PDB 2B3P），使用 Bio.PDB 预计算并列出现所有 C β 原子之间距离在 3.5 Å 至 6.5 Å 的残基对。对精选池中的每条序列，检查是否存在任一预计算残基对同时突变为半胱氨酸（Cys）。若存在，则标记该序列具有“被动二硫键”潜力，在对综合分相近的序列排序时优先保留。

8.3 游离 Cys 风险判据

基于同一 PDB 文件，预先计算每个残基的溶剂可及表面积（SASA，相对值）。若某个位点突变为半胱氨酸且该位点 $\text{SASA} > 40\%$ （即暴露于溶剂），序列中不存在任何其他半胱氨酸与当前 Cys 形成被动二硫键（即 C β 距离在 3.5 - 6.5 Å 内）时，将其标记为“游离 Cys”。

游离半胱氨酸单独存在于蛋白质表面，易发生氧化交联或错误配对，导致蛋白聚集。因此，若某序列含有游离 Cys 且综合分与其他候选接近，则降低其优先级。

九 局限性声明

本设计方案在追求较高预测性能的同时，存在以下系统性局限，特此阐明。

9.1 骨架依赖引起的性能限制风险

本项目完全以 sfGFP 为单一骨架，所有候选序列均通过在其上引入有限突变生成。该策略继承 sfGFP 已优化的折叠与荧光特性，但也天然限制了探索全新折叠结构或序列空间的能力。若 sfGFP 骨架本身已接近该家族的性能上限，则本方案可能难以实现显著提升，存在性能限制风险。

9.2 亮度与热稳定性代理分与实验指标的语义鸿沟

本方案采用 ESM-1v 零样本对数似然值同时作为亮度代理分和热稳定性代理分的基础。该分数评估序列符合天然蛋白质折叠分布的程度，与实验测定的“相对荧光亮度”和“72° C 加热后荧光保留率”属不同物理量。后者除折叠稳定性外，还包含发色团在高温下的耐受性、聚集倾向等因素。因此，代理分仅用于候选序列之间的相对排序，无法确定其绝对数值与实验值呈现线性相关。本方案通过 Spearman 秩相关性分析验证了 ESM-1v 似然值与实验亮度的中等正相关（ $\rho = 0.31$, $p < 0.001$ ），但该相关性仅支持粗粒度的优劣排序，不足以进行精确的定量预测。

9.3 分类排序策略的主观性

为对冲 ESM-1v 代理指标的不确定性，本方案采用分类排序策略（mpnn 取前 3、module 取前 2、ssbond 取 1）。该策略的名额分配（3:2:1）基于对三类序列设计逻辑互补性的定性判断，而非严格的数据驱动优化。若实际实验中 mpnn 序列的得分系统性优于 module 序列（或反之），则固定名额分配可能导致部分高分序列被低分序列替代。本方案在设计文档中明确记录该策略的逻辑依据，供评审方评估其合理性。

9.4 突变模块库的固有限制

突变模块库仅包含十个预选位点及其特定替换氨基酸(S30R、N132D、E138D、Y145F、S147P、H148S、P151T、L155T、I199T、V206K)，完全排除了其他位点或其他氨基酸类型的突变。虽然所有位点均已在 sfGFP 238aa 序列上验证为非同义替换，且每个位点均有独立文献支撑，但整个搜索空间仍被局限在一个有限的子集中。未包含在模块库中的有益突变（包括新型协同组合或非局部位点）将无法被本方案发现。本方案通过引入 ProteinMPNN 从头设计（mpnn 序列）部分弥补了此局限，但 mpnn 序列的生成同样受限于固定的结构模板和温度参数。

参考文献

1. Ahmed, R. D., Jamieson, W. D., Vitsupakorn, D., Zitti, A., Pawson, K. A., Castell, O. K., Watson, P. D., & Jones, D. D. (2025). Molecular dynamics guided identification of a brighter variant of superfolder Green Fluorescent Protein with increased photobleaching resistance. *Communications Chemistry*, 8(1), 174.
2. Bag, S. S., Banerjee, A., Barman, S., & Tiwari, S. (2025). Fluorescent Triazolyl unnatural amino acids in protein engineering: Encoding super folder green fluorescent protein and spectroscopic study. *Bioorganic Chemistry*, 109045.
3. Song, L. (2025). StayRose: A photostable StayGold derivative red-shifted by genetic code expansion. *Journal of Biological Chemistry*, 301(12), 110832.
4. Aliye, N., Fabbretti, A., Lupidi, G., Tsekoa, T., & Spurio, R. (2015). Engineering color variants of green fluorescent protein (GFP) for thermostability, pH-sensitivity, and improved folding kinetics. *Applied Microbiology and Biotechnology*, 99(3), 1205 – 1216.
5. Modi, V., & Morzov, D. (2026). FluProCAD: a computational screening workflow for fluorescent protein variants. *Molecular Physics*, 124(3 – 4), e2458641.
6. Li, X., Perez, R., & Ferrie, J. J. (2025). Accurate Prediction of Protein Tertiary and Quaternary Stability Using Fine-Tuned Protein Language Models and Free Energy Perturbation. *International Journal of Molecular Sciences*, 26(15), 7125.
7. Li, Z., & Luo, Y. (2025). Generalizable and scalable protein stability prediction with rewired protein generative models. *Nature Communications*,

17(1).

8. Zhao, Z. L., Ma, X., Li, L., Zhang, W., Ping, S. Z., Xu, M. Q., & Lin, M. (2011). Protein Cyclization Enhanced Thermostability and Exopeptidase-Resistance of Green Fluorescent Protein. *Journal of Microbiology and Biotechnology*, 21(3).
9. Cava, F., & Berenguer, J. (2008). Expression and use of superfolder green fluorescent protein at high temperatures in vivo: a tool to study extreme thermophile biology. *Environmental Microbiology*, 10(3), 605 – 613.
10. Sarkisyan, K. S., Bolotin, D. A., Meer, M. V., Usmanova, D. R., Mishin, A. S., Sharonov, G. V., Ivankov, D. N., Bozhanova, N. G., Baranov, M. S., Soyomez, O., Bogatyreva, N. S., Vlasov, P. K., Egorov, E. S., Logacheva, M. D., Kondrashov, A. S., Chudakov, D. M., Putintseva, E. V., Mamedov, I. Z., Tawfik, D. S., ... & Kondrashov, F. A. (2016). Local fitness landscape of the green fluorescent protein. *Nature*, 533(7603), 397 – 401.
11. Weinstein, J. Y., Marti-Gomez, C., Lipsh-Sokolik, R., Hoch, S. Y., Liebermann, D., Nevo, R., Weissman, H., Petrovich-Kopitman, E., Margulies, D., Ivankov, D., McCandlish, D. M., & others. (2023). Designed active-site library reveals thousands of functional GFP variants. *Nature Communications*, 14(1), 1 – 13.